



UNIVERSIDAD TECNICA FEDERICO SANTA MARIA

Universidad Técnica Federico Santamaría, Departamento de Informática

Informe Tarea 1

Joaquín Alfredo Fierro Rivas- joaquin.fierro@usm.cl

19 de Agosto de 2026

En este informe presenta el sistema de fotografía computacional que utiliza el filtro bayer, bilinear interpolation e improved linear interpolation.

1. Introducción

La fotografía en color se compone de dos etapas una de muestreo de la señal que genera un mosaico mediante un arreglo de filtro Bayer, también conocido como filtro de color y un etapa computacional que implica un algoritmo de reconstrucción.

1.1. Filtro Bayer

Un mosaico de filtros Bayer (Ver Figura 1) es una matriz de filtros de color (CFA) que organiza filtros de color RGB en una cuadrícula cuadrada de fotosensores. Su disposición particular de filtros de color se utiliza en la mayoría de los sensores de imagen digital de un solo chip empleados en cámaras digitales y videocámaras para crear una imagen en color. El patrón de filtros es mitad verde, un cuarto rojo y un cuarto azul, por lo que también se denomina BGGR, RGBG, GRBG, o RGGB.

Cada uno de los patrones se expone por todo el mosaico, dando la base para la implementación de diversos métodos de interpolación para la reconstrucción de la imagen.

$$R = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, \quad G = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}, \quad B = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}.$$

Donde R corresponde a rojo, G a verde y B a azul.

1.2. Interpolación o Demosaicing

La interpolación consiste en obtener un estimativo del valor del color en un píxel que no posee una muestra por sí sola, como podemos ver en las matrices de más arriba los valores cero son píxeles no conocidos. Para asignarles un valor acorde se suelen usar dos grupos de algoritmos, los no adaptativos y los adaptativos, la diferencia radica en que los primeros usan una fórmula fija para cada píxel, sin importar los detalles de la escena mientras que los adaptativos cambian su funcionamiento según los bordes y formas de la imagen. Estos procesos son también llamados demosaicing.




Figura 1: Mosaico generado del filtro Bayer




Figura 2: Interpolacion Bilinear

Durante el desarrollo de la tarea se implementaron dos métodos de interpolación. El primero se llama Bilinear Interpolation con una leve modificación, la cual se adapta en los pixeles ubicados en las esquinas y bordes de la imagen. El segundo se llama Improved Linear Interpolation (Malvar et al. (2004)) el cual se basa en el uso de un gradiente corrector.

1.2.1. Bilinear Interpolation

Este método de interpolación se basa en el uso de los pixeles vecinos del mismo color para estimar el valor del color del pixel (Ver Figura 2).

$$\hat{g}(i, j) = \frac{1}{4} \sum_{(m,n) \in \{(0,-1), (0,1), (-1,0), (1,0)\}} g(i+m, j+n) \quad (1)$$

Verde: en el caso del filtro verde se calcula el promedio entre los 4 pixeles vecinos. En nuestro caso para los pixeles en las esquinas se toma el promedio entre sus dos pixeles vecinos y en los casos de los bordes se toma el promedio entre los 3 vecinos.

Rojo: si estamos es una posición verde, el valor del pixel se obtendrá a partir del promedio de los dos pixeles adyacentes, si estamos en una posición azul se obtiene el promedio de los 4 pixeles en diagonal a la posición que queremos interpolar. En el caso de los bordes y esquinas, si estamos en una posición azul, tomaremos el valor del único pixel adyacente, si estamos en posición verde tomaremos el valor promedio entre los dos pixeles diagonales adyacentes.

Azul: si estamos es una posición verde, el valor del pixel se obtendrá a partir del promedio de los dos pixeles adyacentes, si estamos en una posición azul se obtiene el promedio de los 4 pixeles en diagonal a la posición que queremos interpolar. En el caso de los bordes y esquinas, si estamos en una posición roja, tomaremos el valor del único pixel adyacente, si estamos en posición verde tomaremos el valor promedio entre los dos pixeles diagonales adyacentes.




Figura 3: Improved Linear Interpolation

1.2.2. Improved Linear Interpolation

Este método se basa en la interpolación anterior donde se le añade el uso de un gradiente más un parámetro de ajuste según el color.

$$\hat{g}(i, j) = \hat{g}_B(i, j) + \alpha \Delta_R(i, j) \quad (2)$$

$$\hat{r}(i, j) = \hat{r}_B(i, j) + \beta \Delta_G(i, j) \quad (3)$$

$$\hat{r}(i, j) = \hat{r}_B(i, j) + \gamma \Delta_B(i, j) \quad (4)$$

$$\Delta_{R|G|B}(i, j) \triangleq r(i, j) - \frac{1}{4} \sum r(i + m, j + n) \quad (5)$$

$$(m, n) = \{(0, -2), (0, 2), (-2, 0), (2, 0)\}$$

Donde la ecuación (2) es la usada para interpolar los colores verdes en posiciones azules y rojas, la ecuación (3) es usada para interpolar los colores rojos y azules en posiciones verdes y la ecuación (4) es usada para interpolar colores rojos en posiciones azules y viceversa. Los 3 parámetros son valores óptimos obtenidos en el estudio que equivalen a $\alpha = 1/2, \beta = 5/8, \gamma = 3/4$. Una equivalencia con el uso de kernels con coeficientes se muestra de la siguiente manera (Ver figura 3) .

Aquí no se vieron los casos de bordes y esquinas como en la anterior interpolación, si no que se añadió un padding de 2 pixeles de grosor con valor 0 para tratar cada pixel con las mismas ecuaciones.

1.3. Métricas

Para comparar la efectividad de los métodos de interpolación se emplearon las siguientes métricas.

1.3.1. Índice de similitud estructural (SSIM)

El Índice de Similitud Estructural (SSIM) es una métrica perceptual que cuantifica la degradación de la calidad de la imagen causada por procesos como la compresión de datos o por pérdidas en la transmisión de datos (Imatest LLC (2015)).

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (6)$$

Donde:

- μ_x y μ_y son las medias locales (promedios de luminancia) de x e y .
- σ_x^2 y σ_y^2 son las varianzas locales (contraste) de x e y .
- σ_{xy} es la covarianza local (similitud estructural) de x e y .
- $C_1 = (K_1L)^2$ y $C_2 = (K_2L)^2$ son constantes estabilizadoras.
- L es el rango dinámico de los valores de los píxeles (típicamente $2^B - 1$, donde B son bits por píxel).
- $K_1 \ll 1$ y $K_2 \ll 1$ son pequeñas constantes escalares.

1.3.2. Relación señal-ruido máxima (PSNR)

Expresa la relación entre el valor máximo posible (potencia) de una señal y la potencia del ruido distorsionador que afecta la calidad de su representación. Dado que muchas señales tienen un rango dinámico muy amplio (relación entre los valores máximo y mínimo posibles de una magnitud variable), la PSNR se suele expresar en la escala logarítmica de decibelios (National Instruments (2023)).

La proporción de señal a ruido está dada por:

$$\text{PSNR} = 10 \cdot \log_{10} \left(\frac{\text{MAX}_I^2}{\text{MSE}} \right) \quad (7)$$

donde MAX_I representa el máximo valor posible para el píxel de la imagen (e.g., 255 para una imagen de 8-bit). El error cuadrático medio está dado por:

$$\text{MSE} = \frac{1}{m \cdot n} \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} [I(i, j) - K(i, j)]^2 \quad (8)$$

1.3.3. Mapeador de Ángulo Espectra (MSI)

Mide la similitud espectral entre los espectros de cada píxel en los datos hiperespectrales de la imagen original y los espectros de referencia especificados de la imagen reconstruida mediante el algoritmo de clasificación del mapeador de ángulo espectral (MathWorks (2020)).

$$\theta = \arccos \left(\frac{\sum_{i=1}^n T_i R_i}{\sqrt{\sum_{i=1}^n T_i^2} \sqrt{\sum_{i=1}^n R_i^2}} \right) \quad (9)$$

Donde:

- θ es el ángulo espectral (generalmente medido en radianes).
- n representa el número total de bandas espectrales.
- T_i es el valor del espectro de prueba/píxel en la banda i .
- R_i es el valor del espectro de referencia/componente extremo en la banda i .

2. Experimentos

Para realizar las pruebas correspondientes, se utilizó un conjunto de 24 imágenes sin pérdida de color (24 bits por píxel, también conocidas como "color completo") liberadas por Kodak (Ver Figura 4).

Se ejecutaron ambos métodos de interpolación para cada una de las 24 imágenes obteniendo las métricas antes descritas, se usó un entorno de Jupyter Notebook con Python. Usando las librerías de Numpy, Pandas, Skimage, Matplotlib (Ver Tablas 1 y 3).




Figura 4: Comparación entre imágenes

Imagen	PSNR	SSIM	SAM
01	26.024862	1.0	0.111993
02	32.066357	1.0	0.101178
03	32.906393	1.0	0.053818
04	32.570901	1.0	0.054861
05	26.467717	1.0	0.128899
06	27.402535	1.0	0.077704
07	32.379626	1.0	0.054225
08	23.601422	1.0	0.120535
09	31.732841	1.0	0.047743
10	31.654734	1.0	0.052199
11	28.940616	1.0	0.090225
12	32.148317	1.0	0.038057
13	23.857779	1.0	0.143095
14	28.788873	1.0	0.092059
15	30.669503	1.0	0.053984
16	30.456001	1.0	0.068227
17	31.976231	1.0	0.070544
18	27.924935	1.0	0.137307
19	28.163663	1.0	0.080756
20	29.857372	1.0	0.041848
21	28.339539	1.0	0.078073
22	30.240109	1.0	0.067135
23	33.499575	1.0	0.045449
24	26.679257	1.0	0.099201

Cuadro 1: Resultados la Interpolación Bilinear

Estadística	Promedio	Desviación Estándar
PSNR	29.514548	2.830900e+00
SSIM	1.000000	5.614662e-15
SAM	0.079546	3.139420e-02

Cuadro 2: Estadísticas de PSNR, SSIM y SAM - Interpolación Bilineal.

Imagen	PSNR	SSIM	SAM
01	29.829328	1.0	0.070790
02	34.954386	1.0	0.076136
03	36.048901	1.0	0.037694
04	36.065704	1.0	0.036534
05	30.714040	1.0	0.076713
06	30.986184	1.0	0.050810
07	35.771423	1.0	0.036631
08	26.985637	1.0	0.079536
09	35.119764	1.0	0.031650
10	35.586365	1.0	0.032411
11	32.714620	1.0	0.057552
12	35.537230	1.0	0.025644
13	28.150088	1.0	0.085769
14	32.070369	1.0	0.063032
15	33.879583	1.0	0.037190
16	33.828254	1.0	0.045626
17	35.034249	1.0	0.048263
18	31.622573	1.0	0.087115
19	31.189827	1.0	0.055559
20	33.582260	1.0	0.026848
21	31.787431	1.0	0.051270
22	33.217198	1.0	0.047122
23	37.127800	1.0	0.030486
24	29.726176	1.0	0.068413

Cuadro 3: Resultados de la interpolacion linear mejorada

Estadística	Promedio	Desviación Estándar
PSNR	32.980391	2.703982e+00
SSIM	1.000000	2.847137e-15
SAM	0.052450	1.942145e-02

Cuadro 4: Estadísticas de PSNR, SSIM y SAM - Interpolacion linear mejorada.

3. Conclusiones

Los resultados muestran que el uso del gradiente de corrección de la interpolación lineal da un incremento positivo en las métricas de PSNR y SAM. En caso de la SSIM, ambos metodos entregan una similitud estructura casi perfecta, la métrica PSNR mejoro un 11,7 % y la métrica SAM disminuyo a un 0,65 % lo cual evidencia una mejora. Esto nos indica que similitud de la forma/dirección del espectro mejora y la fidelidad pixel a pixel también.

Con respecto al PSNR los mejores resultado del método bilinear los obtuvo la imagen 04 y lo mismo ocurrió con la interpolación linear mejorada. Los mejores resultados respecto al SAM los obtuvo la imagen 12 en ambos métodos de interpolación.

Ahora bien hablando de los resultados más bajos, con respecto a la métrica PSNR la obtuvo la imagen 08 en ambos métodos de interpolación, en la métrica SAM imagen 13 tuvo el valor más alto con el método bilinear y la imagen 18 con el método de interpolación linear mejorada. Con respecto a la métrica SSIM, ambos métodos generaron una similitud estructural casi idéntica a la imagen original en todos los casos.

Referencias

- Imatest LLC (2015). Ssim: Structural similarity index. <https://www.imatest.com/docs/ssim/>. Accedido: 2026-08-13.
- Malvar, H. S., He, L.-w., and Cutler, R. (2004). High-quality linear interpolation for demosaicing of bayer-patterned color images. In *2004 IEEE International Conference on Acoustics, Speech, and Signal Processing*, pages V-485–V-488. IEEE.

MathWorks (2020). sam – measure spectral similarity using spectral angle mapper. <https://la.mathworks.com/help/images/ref/sam.html>. Accedido: 2026-08-13.

National Instruments (2023). Peak signal-to-noise ratio as an image quality metric. <https://www.ni.com/en/shop/data-acquisition-and-control/add-ons-for-data-acquisition-and-control/what-is-vision-development-module/peak-signal-to-noise-ratio-as-an-image-quality-metric.html>. Accedido: 2026-08-13.